

# Especificação e Estimação de Modelos Bayesianos

- Seguiremos o livro de Jim Albert “Bayesian Computation with R”
- Qual a ideia?
- Modelos com um parâmetro
- Modelos com múltiplos parâmetros

# Que Proporção de Estudantes dormem 8 horas ou mais por noite?

- Pesquisador buscou na literatura estudos anteriores e descobre: um artigo em que a maioria dorme menos que 6 horas; outro artigo diz que 70 por cento dormem entre 5 e 6 horas, 28% entre 7 e 8, e 2% 9 horas.
- Fundamentado nessa informação o pesquisador acha que  $p < 0.5$ , provavelmente  $p=0.3$ .
- Ela faz uma pesquisa com 27 alunos onde 11 dormiram pelo menos 8 h na noite anterior.

# Como juntar conhecimento anterior e dados novos?

$$L(p) \propto p^s(1-p)^f, 0 < p < 1.$$

The posterior density for  $p$ , by Bayes' rule, is obtained, up to a proportionality constant, by multiplying the prior density by the likelihood:

$$g(p|\text{data}) \propto g(p)L(p).$$

# Como escolher a priori?

- Não tem uma resposta simples e geral.
- Para esse exemplo tentaremos três prioris:
  - Priori discreta
  - Priori contínua
  - Priori de histograma

# Priori Discreta

- Crenças e pesos para valores específicos

.05, .15, .25, .35, .45, .55, .65, .75, .85, .95

are possible values for  $p$ . Based on her beliefs, she assigns these values the corresponding weights

1, 5.2, 8, 7.2, 4.6, 2.1, 0.7, 0.1, 0, 0,

Ver R

# Priori Discreta

- No exemplo tivemos 11 sucessos e 16 fracassos que leva à verossimilhança:

$$L(p) \propto p^{11} (1 - p)^{16}, \quad 0 < p < 1.$$

- No pacote LearnBayes existe a função pdisc para estimar proporções com prioris discretas
- Ver R.  $\text{Prob}(p=0.25, 0.35, 0.45) = 94\%$

# Priori Contínua (Distribuição Beta)

- Podemos alocar probabilidades para cada valor de  $0 < p < 1$  usando uma densidade
- Uma distribuição que aloca densidade nesse intervalo é a distribuição Beta:

$$g(p) \propto p^{a-1} (1-p)^{b-1}, \quad 0 < p < 1,$$

- Mas, como escolher 'a' e 'b'? Uma possibilidade é fixar quantis. Por exemplo:  $\Pr(p < 0.3) = 0.5$  e  $\Pr(p < 0.5) = 0.9$ . (ver R)

# Priori Beta

- Com uma priori Beta(a,b) e dados com 's' sucessos e 'f' fracassos, a distribuição posteriori é:

$$g(p|\text{data}) \propto p^{a+s-1} (1-p)^{b+f-1}, \quad 0 < p < 1,$$

- Quando a distribuição priori e posteriori são da mesma família, chamamos a priori e a verossimilhança de **conjugadas**.
- Para nossa priori e dados temos  $a+s = 3.26+11$  e  $b+f = 7.19+16$ . (ver R)



# Priori Beta

- Estamos com a posteriori, e agora?
- Podemos usar os comandos 'pbeta' e 'qbeta' do R para responder perguntas específicas:
  - Qual a probabilidade que mais que 50% dos alunos dormem 8h ou mais?  $1 - P(p \leq 0.5) = 1 - \text{pbeta}(0.5, a+s, b+f)$
  - Qual o intervalo de credibilidade da posteriori de 90%?  $\text{qbeta}(c(0.5, 0.95), a+s, b+f)$
  - Ver R para encontrar os valores.

# Priori Beta

- Os cálculos da posteriori são exatos, pois conhecemos a distribuição posteriori. E se não conhecêssemos?
- Se tiver como gerar números aleatórios da distribuição posteriori podemos usar nossas estimativas Monte Carlo:
  - $\Pr(p > 0.5)$  = fração de valores acima de 0.5
  - Intervalo de credibilidade de 90% é determinado pelos quantis 0.05 e 0.95 dos valores gerados.
  - Ver R

# Priori de Histograma

- Método de força bruta:
  - Choose a grid of values of  $p$  over an interval that covers the posterior density.
  - Compute the product of the likelihood  $L(p)$  and the prior  $g(p)$  on the grid.
  - Normalize by dividing each product by the sum of the products. In this step, we are approximating the posterior density by a discrete probability distribution on the grid.
  - Using the R command `sample`, take a random sample with replacement from the discrete distribution.

Ver R

# Previsão

- Com nosso conhecimento sobre 'p' (sendo esse conhecimento priori ou posteriori) podemos querer prever o número de sucessos ou fracassos numa amostra futura de 20 alunos
- A densidade preditiva (priori ou posteriori) é dada por:
$$f(\tilde{y}) = \int f(\tilde{y}|p)g(p)dp.$$
- É prior se  $g(p)$  for a priori e posteriori se  $g(p)$  for a posteriori (aqui concentraremos em prioris)

# Previsão (distribuições discretas)

- Para cada valor de 'p' o número de sucessos numa amostra de tamanho 20 segue um binomial:

$$f_B(y|n, p) = \binom{n}{y} p^y (1 - p)^{n-y}, \quad y = 0, \dots, n.$$

- A probabilidade preditiva para  $y \sim$  sucessos numa amostra futura de tamanho m é:

$$f(\tilde{y}) = \sum f_B(\tilde{y}|m, p_i) g(p_i).$$

- A função 'pdiscp' faz isso (ver R)

# Previsão (contínua)

- Se modelar nossa crença sobre 'p' via uma priori Beta(a,b) a integral pode ser resolvida analiticamente para obter:

$$\begin{aligned} f(\tilde{y}) &= \int f_B(\tilde{y}|m, p)g(p)dp \\ &= \binom{m}{\tilde{y}} \frac{B(a + \tilde{y}, b + m - \tilde{y})}{B(a, b)}, \quad \tilde{y} = 0, \dots, m, \end{aligned}$$

- A função 'pbetap' do pacote 'LearnBayes' faz esse cálculo. (ver R)

# Previsão (simulação)

- Se ambos a distribuição de 'p' e o número de sucessos podem ser simulados podemos gerar uma amostra de distribuição preditiva pelos seguintes passos:
  - Amostrar alguns valores de 'p'
  - Para cada valor de 'p' amostrado, amostra um valor de 'Y', o número de sucessos
- Os valores de 'Y' vem da distribuição de previsão. (ver R)

# Previsão (resumos da distribuição)

- Para resumir a distribuição preditiva por um intervalo de resultados que cobre 90% dos valores possíveis, podemos usar a função 'discint' do pacote 'LearnBayes'.
- A função recebe a distribuição dos 'y's e a probabilidade de cobertura desejada e retorna o intervalo e a probabilidade coberta pelo intervalo.
- Aqui temos duas fontes de incerteza. 'p' e o número de sucessos. (ver R)



# Modelos com Um (1) Parâmetro

- Uma maneira de apostar em jogos de futebol americano é pelo número de pontos entre o vencedor e perdedor. Estudaremos a diferença entre o número que o 'bicheiro' oferece a uma chance de 50% e o número observado no jogo. Essa diferença, 'd' deve ter média zero, mas a variância é desconhecida. Vamos estimar essa variância. Sob a hipótese de normalidade temos:

$$L(\sigma^2) \propto (\sigma^2)^{-n/2} \exp \left\{ - \sum_{i=1}^n d_i^2 / (2\sigma^2) \right\}, \quad \sigma^2 > 0.$$

# Estimação da Variância

- Uma priori não informativa sobre a variância é que  $p(\sigma) \sim 1/(\sigma)^2$
- Isso significa que o  $\log(\sigma)$  é uniformemente distribuída na reta (não sabemos a escala)
- Essa prior dá a seguinte posteriori:

$$g(\sigma^2 | \text{data}) \propto (\sigma^2)^{-n/2-1} \exp\{-v/(2\sigma^2)\}$$

- Onde 'v' é a soma dos  $d^2$ .
- O parâmetro  $P=1/(\sigma)^2$ .  $P*v$  segue um Qui-quadrado com 'n' graus de liberdade. (ver R)

# Taxa de Mortalidade (Transplante)

- Para dois hospitais ' $n$ ' (o número de transplantes), ' $y$ ' (o número de mortes) e ' $e$ ' (exposure = soma de  $1/\text{prob}(\text{morte})$ ) são observados.
- Um modelo padrão assume que o número de mortes segue uma distribuição Poisson com média  $e \cdot \lambda$ . Queremos estimar  $\lambda$ .
- Máxima verossimilhança dá  $\lambda = y/e$ , mas isso pode ser ruim para  $y$  pequeno.
- Podemos usar informação priori.

# Taxa de Mortalidade (Transplante)

- Se tiver informação sobre mortes ( $z$ ) e exposição ( $o$ ) de hospitais que achamos que tem uma taxa de mortalidade semelhante podemos criar uma distribuição para  $\lambda$ .
  - Primeiro começa com uma priori não informativa,  $\lambda \sim 1/\lambda$
  - Depois usa os dados dos 10 hospitais semelhantes
  - O conjugado de Poisson é Gamma 
$$p(\lambda) \propto \lambda^{\sum_{j=1}^{10} z_j - 1} \exp \left( - \left( \sum_{j=1}^{10} o_j \right) \lambda \right)$$
- Esta distribuição serve de priori

# Taxa de Mortalidade (Transplante)

- Se o número de mortes observados,  $y$ , segue uma  $\text{Poisson}(e \cdot \lambda)$  e a priori de  $\lambda$  segue uma  $\text{Gamma}(\alpha, \beta)$ , então a posteriori de  $\lambda$  segue uma  $\text{Gamma}(\alpha + y, \beta + e)$
- A distribuição preditiva (da priori) é:

$$f(y) = \frac{f(y|\lambda)g(\lambda)}{g(\lambda|y)},$$

where  $f(y|\lambda)$  is the  $\text{Poisson}(e\lambda)$  sampling density and  $g(\lambda)$  and  $g(\lambda|y)$  are, respectively, the prior and posterior densities of  $\lambda$ .

# Taxa de Mortalidade (Transplante)

- Para verificar esses modelos, é importante comparar o resultado obtido de  $y$  com a distribuição de previsão de  $y$ .
- Se tiver no 'centro' da distribuição preditiva, então não temos razões de desacreditar o modelo.
- Se tiver nas cuadas da distribuição preditiva, então pode ser que nossa priori ou nosso modelo de amostra sejam errados.
- (Ver R)

# Robustez Bayesiano

- As vezes várias prioris podem refletir nossas crenças
- Nesses casos é importante verificar que os resultados finais não são sensíveis à escolha da priori
- Exemplo: João tem um QI típico,  $\theta$ , então achamos que a mediana é 100 e 90% dos valores estão entre 80 e 120.
- Ver R para a escolha de uma priori possível.

# Robustez Bayesiano

- João faz quatro exames de QI. Assumindo que são independentes com média  $\theta$  e desvio padrão 15, a média das quatro medições segue uma  $\text{Normal}(\theta, \sigma/\sqrt{4})$
- A posteriori é encontrada com precisão  $P=1/\sigma^2$  igual à soma das precisões da priori e dos dados.
- A média da posteriori é a média ponderada pelas precisões da priori e dos dados (ver próxima página)



# Robustez Bayesiano

$$P_1 = P_D + P = 4/\sigma^2 + 1/\tau^2,$$

The posterior standard deviation is given by

$$\tau_1 = 1/\sqrt{P_1} = 1/(\sqrt{4/\sigma^2 + 1/\tau^2}).$$

The posterior mean of  $\theta$  can be expressed as a weighted average of the sample mean and the prior mean where the weights are proportional to the precisions:

$$\mu_1 = \frac{\bar{y}P_D + \mu P}{P_D + P} = \frac{\bar{y}(4/\sigma^2) + \mu(1/\tau^2)}{4/\sigma^2 + 1/\tau^2}.$$

- Calculamos as estimativas para três médias diferentes, 110, 125 e 140. (ver R)

# Robustez Bayesiano

- Uma densidade priori alternativa é a distribuição t de student com dois graus de liberdade (ver R para comparar com a Normal)

We perform the posterior calculations using the t prior for each of the possible sample results. Note that the posterior density of  $\theta$  is given, up to a proportionality constant, by

$$g(\theta|\text{data}) \propto \phi(\bar{y}|\theta, \sigma/\sqrt{n})g_T(\theta|v, \mu, \tau),$$

where  $\phi(y|\theta, \sigma)$  is a normal density with mean  $\theta$  and standard deviation  $\sigma$ , and  $g_T(\mu|v, \mu, \tau)$  is a t density with median  $\mu$ , scale parameter  $\tau$ , and degrees of freedom  $v$ . Since this density does not have a convenient functional

# Misturas de Prioris Conjugadas

- Vimos que para os modelos de amostragem Normal, Poisson e Binomial, as prioris podem ser escolhidas para ter posteriors da mesma distribuição. (são conjugadas)
- Estes modelos podem parecer pouco flexíveis, mas nesses casos, misturas dessas prioris são também conjugadas.

# Misturas de Prioris Conjugadas

- Considera uma moeda viciada num sentido desconhecido
- Podemos usar uma priori que mistura distribuições betas centradas em 0.3 e 0.7 com pesos de mistura iguais ( $\gamma=0.5$ )
- $g(p) = \gamma g_1(p) + (1 - \gamma)g_2(p)$
- A posteriori após observar os dados é
$$g(p|\text{data}) = \gamma(\text{data})g_1(p|\text{data}) + (1 - \gamma(\text{data}))g_2(p|\text{data})$$
- Com  $\gamma(\text{data}) = \frac{\gamma f_1(s, f)}{\gamma f_1(s, f) + (1 - \gamma)f_2(s, f)}$

# Misturas de Prioris Conjugadas

- No coeficiente de mistura,  $f_i$  é a distribuição preditiva para caso  $i$ .

$$\gamma(\text{data}) = \frac{\gamma f_1(s, f)}{\gamma f_1(s, f) + (1 - \gamma) f_2(s, f)}$$

- A função 'binomial.beta.mix' calcula a posteriori dado o número de sucessos e fracassos observados.
- Ver R

# Teste Bayesiano da Moeda Viciada

- Um teste clássico de uma moeda viciada se fundamenta num p-valor calculada como  $2 \cdot \min(P(Y \leq Y_{\text{obs}}), P(Y \geq Y_{\text{obs}}))$ . No caso de 5 caras em 20 lançamentos sob  $H_0$  de  $p=0.5$ , o p-valor é 0.042, o que levaria a rejeitar a hipótese nula.
- Pode usar um modelo Bayesiano onde duas possibilidades existem
  - A moeda é justa ( $p=0.5$ ) com probabilidade 0.5
  - A moeda não é justa ( $p \neq 0.5$ )

# Teste Bayesiano da Moeda Viciada

- O segundo modelo pode ser especificado como um modelo  $\text{beta}(a,a)$  onde valores menores de  $a$  levam a densidades que cobrem mais do intervalo entre 0 e 1. A priori total fica:
- $g(p) = .5I(p = .5) + .5I(p \neq .5)g_1(p)$
- E a posteriori é dada por
- $g(p|y) = \lambda(y)I(p = .5) + (1 - \lambda(y))g_1(p|y)$
- Onde  $\lambda(y)$  representa a probabilidade de  $H_0$  ser verdadeiro.

# Teste Bayesiano da Moeda Viciada

- $\lambda(y)$  é dada por:  $\lambda(y) = \frac{.5p(y|.5)}{.5p(y|.5) + .5m_1(y)}$
- Onde  $m_1(y)$  é a densidade preditiva priori usando a distribuição  $\text{beta}(a,a)$ , dada por:
- $m_1(y) = \frac{f(y|p)g_1(p)}{g_1(p|y)}$
- Ver R para o cálculo (note como o valor de 'a' não importa)



# Teste Bayesiano da Moeda Viciada

- E se o teste fosse fundamentado em a probabilidade de ser menor que o valor observado ao invés de igual ao valor observado?

$$\lambda(y) = \frac{.5P_0(Y \leq 5)}{.5P_0(Y \leq 5) + .5P_1(Y \leq 5)}$$

- Ver R para o resultado.

# Modelos com Múltiplos Parâmetros

- Dados Normais com média e variância desconhecida
- Considera os tempos para terminar a maratona de Nova Iorque para homens entre 20-29 anos
- Para uma amostra aleatória da normal e priori não informativa ( $P(\sigma, \mu) \sim 1/\sigma^2$ ) a posteriori é:

$$g(\mu, \sigma^2 | y) \propto \frac{1}{(\sigma^2)^{n/2+1}} \exp \left( -\frac{1}{2\sigma^2} (S + n(\mu - \bar{y})^2) \right)$$

# Modelo Normal

- the posterior of  $\mu$  conditional on  $\sigma^2$  is distributed as  $N(\bar{y}, \sigma / \sqrt{n})$
- the marginal posterior of  $\sigma^2$  is distributed as  $S\chi_{n-1}^{-2}$ , where  $\chi_{\nu}^{-2}$  denotes an inverse chi-square distribution with  $\nu$  degrees of freedom
- Isso permite simulação do posteriori pelo marginal da variância primeiro seguida pela condicional da média
- Intervalos de credibilidade marginais podem ser calculados dos dados gerados da distribuição conjunta
- Ver R

# Modelo Multinomial

- Em 1998 CBS fez um levantamento sobre intenções de votos nos EUA entre Bush e Dukakis. De 1447 adultos,  $y_1=727$  apoiaram Bush,  $y_2=583$  Dukakis e  $y_3=137$  outros ou indecisos.
- A fração que apoia Bush ( $\theta_1$ ) é maior que a fração que apoia Dukakis ( $\theta_2$ )?
- Priori uniforme sobre as frações leva à posteriori Dirichlet:  $g(\theta) = \theta_1^{y_1} \theta_2^{y_2} \theta_3^{y_3}$
- Com  $\theta_1 + \theta_2 + \theta_3 = 1$

# Modelo Multinomial

- Para examinar  $(\theta_1 - \theta_2)$  o caminho mais natural é simular da posteriori para os três  $\theta$ s. Depois pode examinar a distribuição de  $\theta_1 - \theta_2$  ou contar a fração de vezes que  $\theta_1 > \theta_2$ .
- Ver R

# Modelo Multinomial

- Vamos estimar o número de votos eleitorais do Obama em 2008.
- Para tal usaremos um conjunto de pesquisas de intenção de voto contendo uma fração que apoia Obama e uma fração que apoia McCain para cada estado.
- O número de votos eleitorais para Obama é dado por

$$EV_O = \sum_{j=1}^{51} EV_j I(\theta_{Oj} > \theta_{Mj})$$

# Modelo Multinomial

- Assumiremos que cada pesquisa entrevistou 500 pessoas (suposição conservador)
- E uma priori uniforme sobre  $\theta_O$  e  $\theta_M$  leva a posteriors independentes para cada estado com parâmetros

$$(\theta_O; \theta_M; 1-\theta_O - \theta_M) = (500*f_O + 1; 500*f_M+1, 500*(1-f_O-f_M)+1)$$

- Com a distribuição posteriori, dá para simular
- Ver R

# Comparação de Duas Proporções

- Observamos  $y_1 \sim \text{Bin}(n_1, p_1)$  e  $y_2 \sim \text{Bin}(n_2, p_2)$
- Queremos saber se  $p_1 > p_2$  ou  $p_2 > p_1$
- Se  $p_1$  e  $p_2$  forem independentes, então cada um pode ter suas densidades prioris e posterioris da Beta. O cálculo da probabilidade de  $p_1 > p_2$  é direto.
- Exploramos a possibilidade de  $p_1$  e  $p_2$  serem associados



# Comparação de Duas Proporções

- Se  $p_1=0.8$  isso pode afetar nossa crença sobre  $p_2$  (fazer ele aparecer mais perto de 0.8, por exemplo)
- O modelo de Howard é:  $\theta_1 = \log \frac{p_1}{1-p_1}, \theta_2 = \log \frac{p_2}{1-p_2}$
- $g(p_1, p_2) \propto e^{-(1/2)u^2} p_1^{\alpha-1} (1-p_1)^{\beta-1} p_2^{\gamma-1} (1-p_2)^{\delta-1}, 0 < p_1, p_2 < 1,$
- Onde  $u = \frac{1}{\sigma}(\theta_1 - \theta_2)$
- Sigma controla quão próximas as proporções devem ser. Sigma pequena  $\rightarrow$  próximas
- Alpha e beta: priori de  $p_1$
- Gamma e delta: priori de  $p_2$

# Comparação de Duas Proporções

- Com dados binomiais a verossimilhança é:
- $L(p_1, p_2) \propto p_1^{y_1} (1 - p_1)^{n_1 - y_1} p_2^{y_2} (1 - p_2)^{n_2 - y_2}, 0 < p_1, p_2 < 1$
- E a posteriori segue a priori com parâmetros atualizados:  $(\alpha + y_1, \beta + n_1 - y_1, \gamma + y_2, \delta + n_2 - y_2, \sigma)$
- Examinaremos a tabela a seguir:
- Ver R

Table 4.3. Pearson's example.

	Successes	Failures	Total
Sample 1	3	15	18
Sample 2	7	5	12
Totals	10	20	30